Prädiktion der koronaren Herzkrankheit (KHK)

Statistische Modellierung und Entwicklung eines Screening-Tools

Eure Namen / Gruppenname

2026-03-13

Contents

1 Einleitung & Forschungsfrage **2**

2 Datengrundlage & Datenaufbereitung **3**

2.1 Variablenübersicht 4

2.2 Datenbereinigung im Code 5

3 Explorative Datenanalyse (EDA) **6**

3.1 Hypothesentests (Chi-Quadrat & ANOVA) 6

3.2 Visuelle Analyse 9

4 Statistische Modellierung **15**

4.1 Basismodell (13 Variablen) 16

4.2 Optimiertes Modell (Rückwärts-Selektion) 18

5 Modellevaluation und Schwellenwert-Analyse **23**

5.1 Standard-Evaluation (50%) & ROC-Kurve 23

5.2 Klinische Rekalibrierung (20%) 29

6 Methoden-Stresstest: Kreuzvalidierung & Machine Learning **30**

7 Transfer in die klinische Praxis: Das Screening-Modell **32**

7.1 Gatekeeper-Modell & ESC-Triage 33

7.2 100-fache Monte-Carlo-Simulation 36

8 Interaktive Diagnose-Applikation (R-Shiny) 37

9 Diskussion & Fazit 40

9.1 Zusammenfassung der Ergebnisse 40

9.2 Limitierungen der Arbeit 40

9.3 Ausblick und zukünftige Entwicklungen 41

1 Einleitung & Forschungsfrage

Herz-Kreislauf-Erkrankungen, insbesondere ischämische Herzkrankheiten wie die koronare Herzkrankheit (KHK), stellen laut der Weltgesundheitsorganisation (WHO) weltweit die führende Todesursache dar. Die KHK, in aktuellen Leitlinien oft unter dem Begriff der chronischen Koronarsyndrome (CCS) zusammengefasst, ist durch eine fortschreitende Arteriosklerose der Herzkranzgefässe gekennzeichnet. Diese Verengung führt zu einer verminderten Sauerstoffversorgung des Herzmuskels, was sich klinisch häufig als Angina Pectoris äussert und unbehandelt in einem lebensbedrohlichen Myokardinfarkt resultieren kann. Eine frühzeitige und präzise Diagnostik ist daher von entscheidender prognostischer Bedeutung.

In der klinischen Praxis stellt die Erstdiagnostik eine erhebliche Herausforderung dar. Die definitive Bestätigung oder der Ausschluss einer KHK erfordert oft ressourcenintensive, teure oder invasive Verfahren, wie beispielsweise die Myokard-Szintigraphie, das Stress-MRT oder die invasive Koronarangiographie (Herzkatheter). Da diese Verfahren nicht flächendeckend als Erstlinientest eingesetzt werden können, kommt der Primärversorgung (Hausarztpraxis) eine essenzielle Triage- und Gatekeeper-Funktion zu. Es bedarf effizienter Entscheidungshilfen, um Patienten mit unklaren Brustschmerzen schnell und sicher anhand leicht erhebbarer Basisparameter in entsprechende Risikogruppen einzuteilen.

Vor diesem medizinischen und gesundheitsökonomischen Hintergrund leitet sich die zentrale Forschungsfrage dieser Arbeit ab: **Mit welcher diagnostischen Genauigkeit lässt sich das Vorliegen einer koronaren Herzkrankheit durch physiologische und klinische Parameter vorhersagen?**

Um diese Frage zu beantworten, verfolgt die vorliegende Arbeit ein zweistufiges Ziel: Im ersten Schritt wird anhand des historischen "Cleveland Heart Disease"-Datensatzes ein statistisch optimiertes Klassifikationsmodell (logistische Regression) entwickelt und evaluiert. Im zweiten Schritt liegt der Fokus auf der praktischen Translation: Ziel ist es, aus den statistischen Erkenntnissen ein praxistaugliches, Screening-Tool zu extrahieren. Dieses soll ausschliesslich auf einfach zu erfassenden Basisparametern beruhen und sich an den aktuellen Triage-Leitlinien der European Society of Cardiology (ESC) orientieren. Das finale Modell wird schliesslich in einen Prototyp eines interaktiven Clinical Decision Support Systems (CDSS) überführt.

2 Datengrundlage & Datenaufbereitung

Für die vorliegende Analyse wurde der "Cleveland Heart Disease"-Datensatz aus dem UCI Machine Learning Repository herangezogen. Ursprünglich umfasste der Datensatz n = 303 Beobachtungen klinischer Patientendaten. Im Rahmen eines Preprocessings wurden die Daten zunächst auf Inkonsistenzen und fehlende Werte (im Originaldatensatz teilweise als "?" kodiert) geprüft. Um Verzerrungen in den späteren Machine-Learning-Modellen zu vermeiden, wurden sechs unvollständige Fälle vollständig aus dem Datensatz entfernt (Listwise Deletion). Die finale, bereinigte Stichprobe für die Modellierung beläuft sich somit auf n = 297 Patienten.

Ein zentraler methodischer Schritt der Datenaufbereitung war die Transformation der abhängigen Zielvariable `num`. Im Originaldatensatz gibt diese den angiografischen Schweregrad der koronaren Herzkrankheit auf einer Skala von 0 (keine Gefässverengung) bis 4 (schwere Mehrgefässerkrankung) an. Für die Zwecke dieser Arbeit wurde diese multikategoriale Variable in eine binäre Klassifikation überführt: Der Wert 0 wurde als "gesund" (Klasse 0) beibehalten, während sämtliche Ausprägungen von 1 bis 4 unter der Klasse "krank" (Klasse 1) zusammengefasst wurden.

Diese Binarisierung ist primär in der geringen Stichprobengrösse begründet. Der Versuch, ein prädiktives Modell für fünf separate Ausprägungen auf Basis von lediglich 297 Patienten zu trainieren, würde zu einer massiven Zersplitterung der Daten (Class Imbalance) und somit zu instabilen Schätzern führen. Durch die Reduktion auf eine dichotome Fragestellung wird das Modell exakt auf die klinisch relevanteste Triage-Entscheidung fokussiert.

2.1 Variablenübersicht

Der verwendete Cleveland-Datensatz umfasst nach der Bereinigung 14 klinisch relevante Attribute. Die folgende Tabelle bietet eine Übersicht über die verwendeten physiologischen Parameter, deren Bedeutung sowie ihre Ausprägungen:

Variable	Beschreibung	Ausprägungen / Datentyp
`age`	Alter der Patienten	Kontinuierlich (in Jahren)
`sex`	Geschlecht	Binär (1 = Männlich, 0 = Weiblich)
`cp`	Brustschmerztyp (*Chest Pain*)	Kategorial (1 = typische Angina, 2 = atypische Angina, 3 = nicht-anginöser Schmerz, 4 = asymptomatisch)
`trestbps`	Ruheblutdruck bei Klinikaufnahme	Kontinuierlich (in mm Hg)
`chol`	Serumcholesterin	Kontinuierlich (in mg/dl)
`fbs`	Nüchternblutzucker > 120 mg/dl	Binär (1 = Ja, 0 = Nein)
`restecg`	Ruhe-EKG-Ergebnisse	Kategorial (0 = normal, 1 = ST-T-Wellen-Anomalie, 2 = wahrscheinliche/definitive Linksherzhypertrophie)
`thalach`	Maximal erreichte Herzfrequenz	Kontinuierlich (Schläge pro Minute)
`exang`	Belastungsinduzierte Angina pectoris	Binär (1 = Ja, 0 = Nein)
`oldpeak`	ST-Senkung durch Belastung (relativ zur Ruhe)	Kontinuierlich

Variable	Beschreibung	Ausprägungen / Datentyp
slope	Steigung des maximalen Belastungs-ST-Segments	Kategorial (1 = ansteigend, 2 = flach, 3 = abfallend)
ca	Anzahl der Hauptgefässe, gefärbt durch Fluoroskopie	Ordinal (0 bis 3)
thal	Thallium-Szintigraphie (Nuklearmedizin. Test)	Kategorial (3 = normal, 6 = fixierter Defekt, 7 = reversibler Defekt)
num / target	Diagnose der koronaren Herzkrankheit (Zielvariable)	Ursprünglich 0-4. Binarisiert: 0 = Gesund, 1 = Krank

2.2 Datenbereinigung im Code

Im folgenden code werden die Daten wie zuvor beschrieben bereinigt undd vorbereitet.

```
# 1. Daten laden
heart_disease <- fetch_ucirepo(id = 45)
df <- bind_cols(heart_disease$data$features, heart_disease$data$targets)

# 2. Fehlerhafte Werte (?) mit echtem NA ersetzen und Typen korrigieren
df[df == "?"] <- NA
df$ca <- as.numeric(as.character(df$ca))
df$thal <- as.numeric(as.character(df$thal))

# 3. Zielvariable binarisieren (0 = Gesund, 1 = Krank) und 'num' entfernen
df_modell <- df %>%
  mutate(target = as.factor(ifelse(num > 0, "1", "0"))) %>%
  select(-num)
```

```r
# 4. Löschen aller fehlenden Werte für sauberes Machine Learning
df_modell <- na.omit(df_modell)

# Kontrolle der Dimensionen (Erwartet: 297 Zeilen, 14 Spalten)
#dim(df_modell)
```

3 Explorative Datenanalyse (EDA)

Um ein tiefgreifendes Verständnis für die zugrundeliegende Datenstruktur zu gewinnen und erste Hypothesen abzuleiten, wurde eine umfassende explorative Datenanalyse (EDA) durchgeführt.

Zunächst wurden die kategorialen Variablen mittels Kreuztabellen und Pearson-Chi-Quadrat-Tests auf ihre stochastische Unabhängigkeit geprüft. Hierbei zeigte sich ein hochsignifikanter Zusammenhang beim Brustschmerztyp (`cp`, $p < 0.001$) und beim Geschlecht (`sex`, $p < 0.001$).

Für die kontinuierlichen Variablen wurden Varianzanalysen (ANOVA) durchgeführt. Die Ergebnisse belegen, dass sich erkrankte Patienten hinsichtlich ihres höheren Alters (`age`, $p < 0.001$), eines höheren Ruheblutdrucks (`trestbps`, $p = 0.008$) und insbesondere einer deutlich niedrigeren maximal erreichten Herzfrequenz (`thalach`, $p < 0.001$) signifikant von der gesunden Gruppe unterscheiden.

Abschliessend wurde eine Korrelationsmatrix aller numerischen Variablen erstellt, um potenzielle Multikollinearität zu prüfen. Die Inspektion der Matrix zeigt, dass die Korrelationen zwischen den unabhängigen Variablen in einem unkritischen Bereich liegen, weshalb alle Parameter in das initiale Basismodell aufgenommen werden können.

3.1 Hypothesentests (Chi-Quadrat & ANOVA)

```r
# --- 1. Chi-Quadrat-Tests (Kategoriale Variablen) ---
chisq.test(table(df_modell$cp, df_modell$target))   # Brustschmerztyp
```

```
##
##  Pearson's Chi-squared test
##
## data:  table(df_modell$cp, df_modell$target)
## X-squared = 77.276, df = 3, p-value < 2.2e-16
```

```r
chisq.test(table(df_modell$sex, df_modell$target))  # Geschlecht
```

```
##
##  Pearson's Chi-squared test with Yates' continuity correction
##
## data:  table(df_modell$sex, df_modell$target)
## X-squared = 21.852, df = 1, p-value = 2.946e-06
```

```r
chisq.test(table(df_modell$fbs, df_modell$target))  # Nüchternblutzucker
```

```
##
##  Pearson's Chi-squared test with Yates' continuity correction
##
## data:  table(df_modell$fbs, df_modell$target)
## X-squared = 1.9997e-31, df = 1, p-value = 1
```

```r
# --- 2. Varianzanalysen / ANOVA (Kontinuierliche Variablen) ---
summary(aov(age ~ target, data = df_modell))        # Alter
```

```
##              Df Sum Sq Mean Sq F value   Pr(>F)
## target        1   1250  1250.0   16.04 7.86e-05 ***
## Residuals   295  22992    77.9
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
summary(aov(trestbps ~ target, data = df_modell))   # Ruheblutdruck
```

```
##              Df Sum Sq Mean Sq F value  Pr(>F)
## target        1   2200  2200.3   7.118 0.00805 **
## Residuals   295  91193   309.1
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
summary(aov(chol ~ target, data = df_modell))       # Cholesterin
```

```
##              Df Sum Sq Mean Sq F value Pr(>F)
## target        1   5159    5159   1.914  0.168
## Residuals   295 795151    2695
```

Um den Fokus der Untersuchung gezielt auf die Entwicklung des späteren, praxistauglichen Screening-Modells (siehe Kapitel 7) zu legen, konzentriert sich die inferenzstatistische Überprüfung der explorativen Datenanalyse auf exakt jene sechs Basisparameter, die für das finale Hausarzt-Triage-Tool relevant sind: Alter (`age`), Geschlecht (`sex`), Brustschmerztyp (`cp`), Ruheblutdruck (`trestbps`), Serumcholesterin (`chol`) und Nüchternblutzucker (`fbs`).

Die Pearson-Chi-Quadrat-Tests belegen einen hochsignifikanten Zusammenhang zwischen dem Brustschmerztyp ($X^2 = 77.28$, $p < 0.001$) sowie dem Geschlecht ($X^2 = 21.85$, $p < 0.001$) und der Zielvariable (KHK-Diagnose). Der Nüchternblutzucker (`fbs`) hingegen verfehlt in dieser isolierten, univariaten Betrachtung das statistische Signifikanzniveau ($p = 1.000$) völlig.

Ein konsistentes Bild zeigt sich bei den kontinuierlichen Parametern mittels einfaktorieller Varianzanalyse (ANOVA). Während sich gesunde und erkrankte Patienten hinsichtlich ihres Alters ($F = 16.04$, $p < 0.001$) und des Ruheblutdrucks ($F = 7.12$, $p = 0.008$) statistisch signifikant unterscheiden, weisen die mittleren Serumcholesterinwerte (`chol`) zwischen den beiden Diagnosegruppen univariat keinen signifikanten Unterschied auf ($F = 1.91$, $p = 0.168$).

Klinische Einordnung der nicht-signifikanten Prädiktoren

Dass Cholesterin und Nüchternblutzucker in der isolierten Betrachtung nicht signifikant trennen, widerspricht nicht ihrer medizinischen Relevanz. In der kardiologischen Pathophysiologie sind Hyperlipidämie (erhöhtes Cholesterin) und Diabetes mellitus (erhöhter Blutzucker) elementare, systemische Risikofaktoren. Sie begünstigen die Arteriosklerose über Jahre hinweg und entfalten ihre prädiktive Kraft häufig erst im multivariaten Zusammenspiel mit anderen Parametern (wie Alter und Blutdruck). Da die aktuellen Leitlinien der European Society of Cardiology (ESC) den Lipid- und Glukosestatus für die systematische Risikostratifizierung explizit einfordern, werden diese beiden Parameter methodisch und klinisch fundiert in die anschliessende Regressionsmodellierung übernommen.

3.2 Visuelle Analyse

```r
# --- 1. VISUELLE EDA: Kontinuierliche Basisparameter (Boxplots) ---
plot_kontinuierlich <- df_modell %>%
  select(target, age, trestbps, chol) %>%
  pivot_longer(cols = -target, names_to = "Variable", values_to = "Wert") %>%
  ggplot(aes(x = target, y = Wert, fill = target)) +
  geom_boxplot(alpha = 0.7, outlier.colour = "red", outlier.shape = 16) +
  facet_wrap(~ Variable, scales = "free_y") +
  scale_fill_manual(values = c("0" = "#1b9e77", "1" = "#d95f02"),
                    labels = c("0" = "Gesund", "1" = "Krank")) +
  theme_minimal() +
  labs(title = "Verteilung der kontinuierlichen Basisparameter",
       x = "Diagnose (0 = Gesund, 1 = Krank)", y = "Wert", fill = "Status") +
  theme(legend.position = "bottom")

print(plot_kontinuierlich)
```

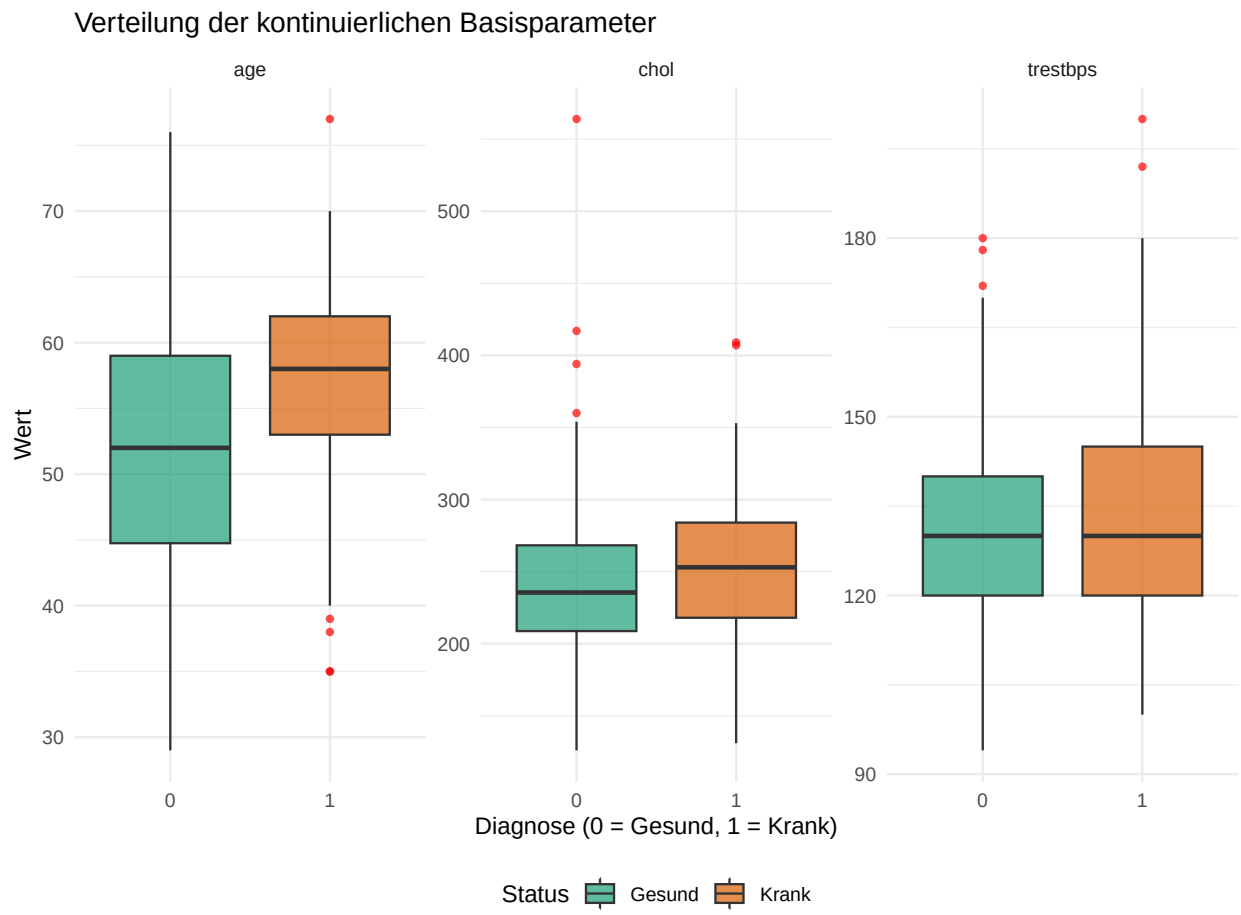


```r
# --- 2. VISUELLE EDA: Kategoriale Basisparameter (Balkendiagramme) ---

# Plot für Brustschmerztyp (cp)
plot_cp <- ggplot(df_modell, aes(x = factor(cp), fill = target)) +
  geom_bar(position = "fill", alpha = 0.8) +
  scale_fill_manual(values = c("0" = "#1b9e77", "1" = "#d95f02")) +
  theme_minimal() +
  labs(title = "KHK-Anteil nach Brustschmerztyp (cp)",
       x = "Brustschmerztyp (1 bis 4)", y = "Anteil", fill = "Status")

print(plot_cp)
```

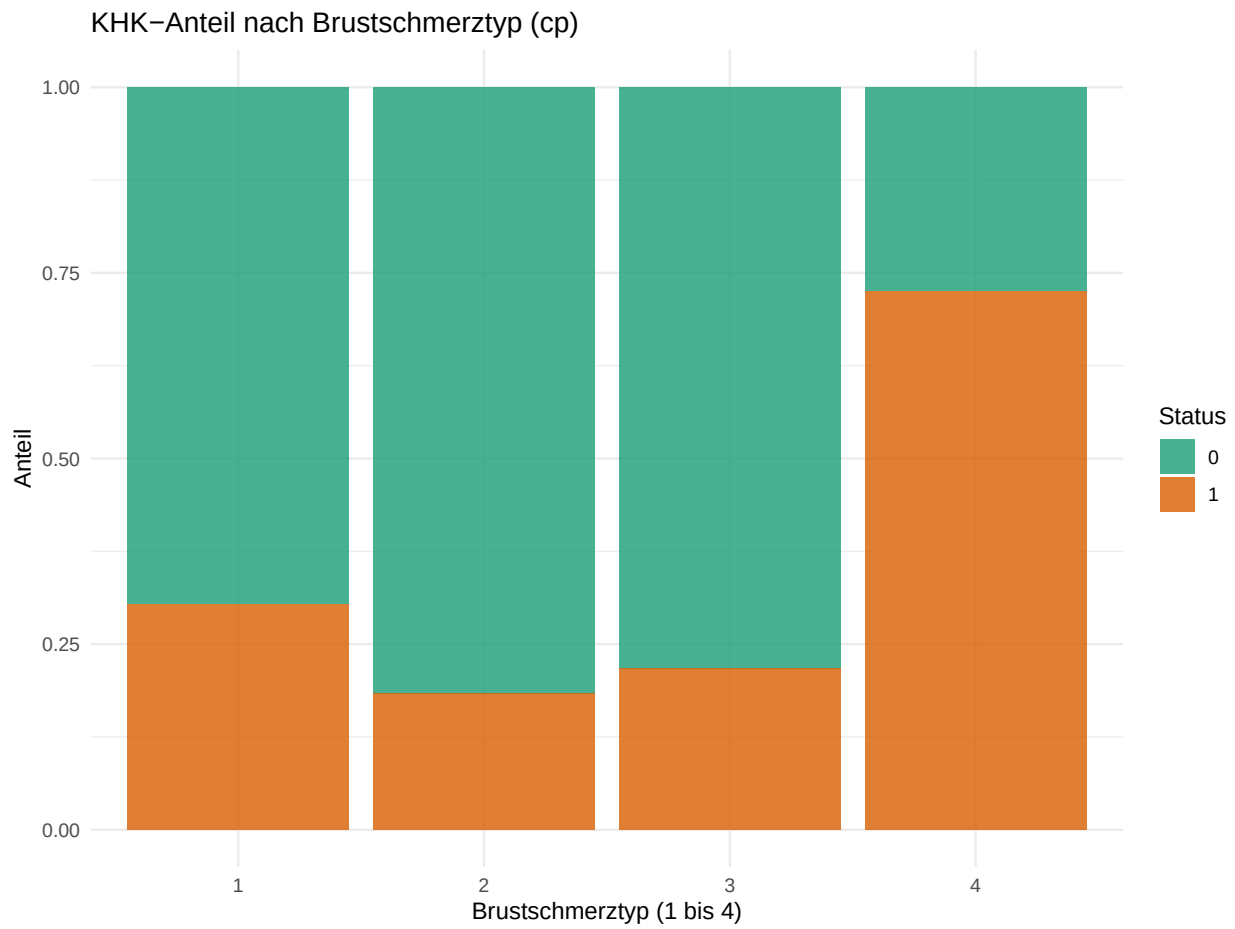


```r
# Plot für Geschlecht (sex)
plot_sex <- ggplot(df_modell, aes(x = factor(sex), fill = target)) +
  geom_bar(position = "fill", alpha = 0.8) +
  scale_fill_manual(values = c("0" = "#1b9e77", "1" = "#d95f02")) +
  scale_x_discrete(labels = c("0" = "Weiblich", "1" = "Männlich")) +
  theme_minimal() +
  labs(title = "KHK-Anteil nach Geschlecht (sex)",
       x = "Geschlecht", y = "Anteil", fill = "Status")

print(plot_sex)
```

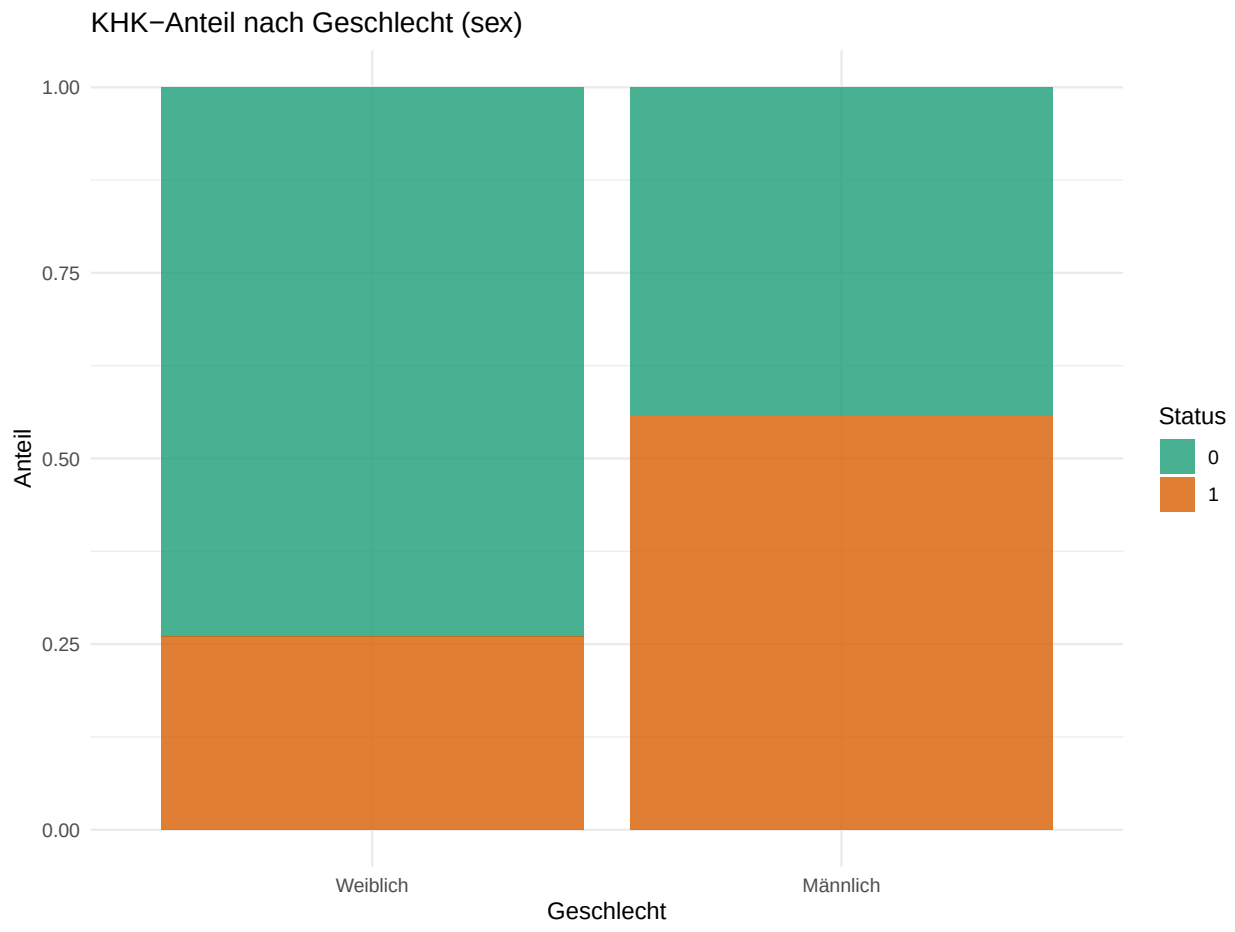


```r
# Plot für Nüchternblutzucker (fbs)
plot_fbs <- ggplot(df_modell, aes(x = factor(fbs), fill = target)) +
  geom_bar(position = "fill", alpha = 0.8) +
  scale_fill_manual(values = c("0" = "#1b9e77", "1" = "#d95f02"),
                    labels = c("0" = "Gesund", "1" = "Krank")) +
  scale_x_discrete(labels = c("0" = "Normal", "1" = "> 120 mg/dl")) +
  theme_minimal() +
  labs(title = "KHK-Anteil nach Nüchternblutzucker (fbs)",
       x = "Blutzucker", y = "Anteil", fill = "Status")

print(plot_fbs)
```

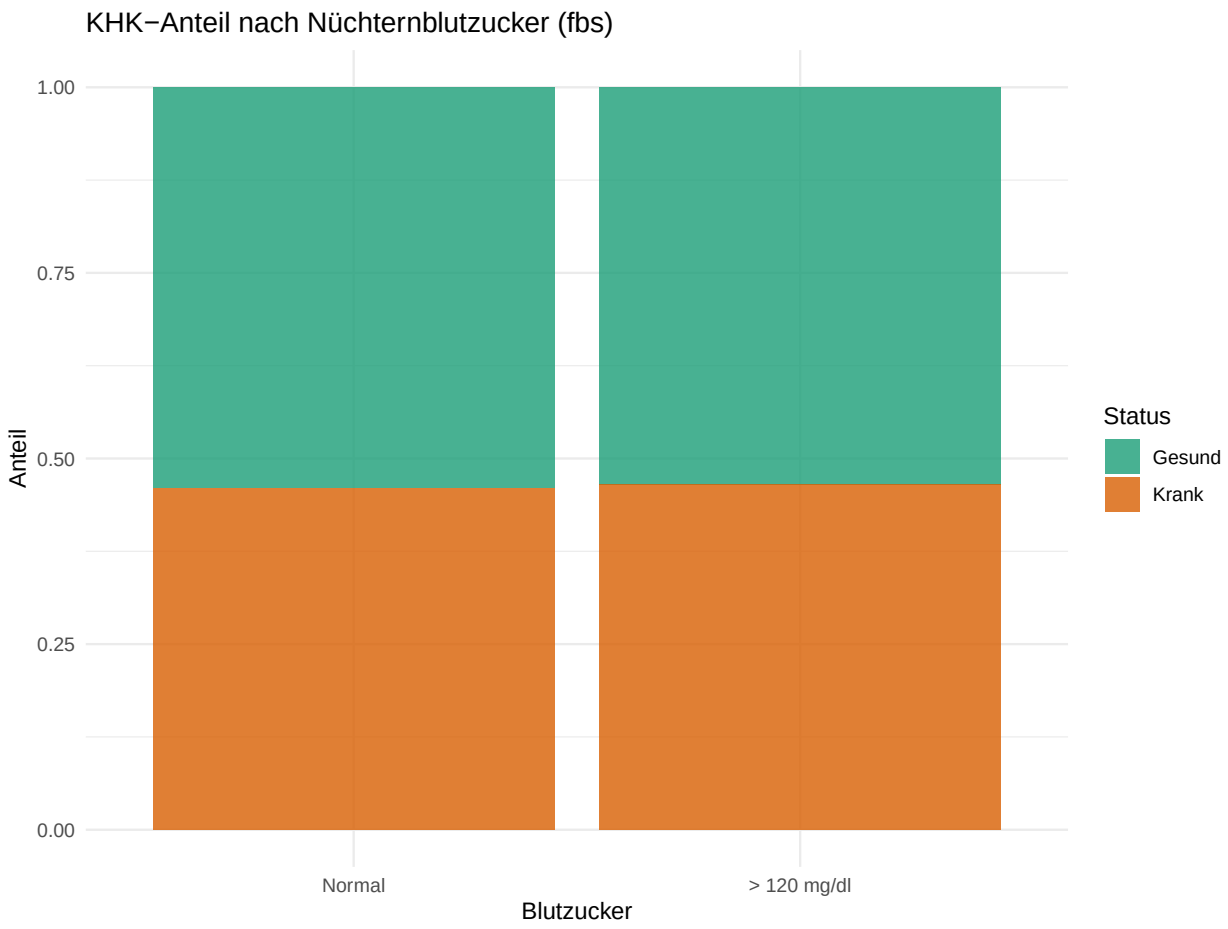


```r
# --- 3. VISUELLE EDA: Multikollinearität (Gesamte Korrelationsmatrix) ---
df_numerisch <- df_modell %>% mutate(across(everything(), as.numeric))
korrelations_matrix <- cor(df_numerisch, use = "complete.obs")

corrplot(korrelations_matrix, method = "color", type = "upper",
         addCoef.col = "black", number.cex = 0.6, tl.col = "black",
         tl.srt = 45, diag = FALSE, title = "Korrelationsmatrix aller Parameter",
         mar = c(0,0,2,0))
```

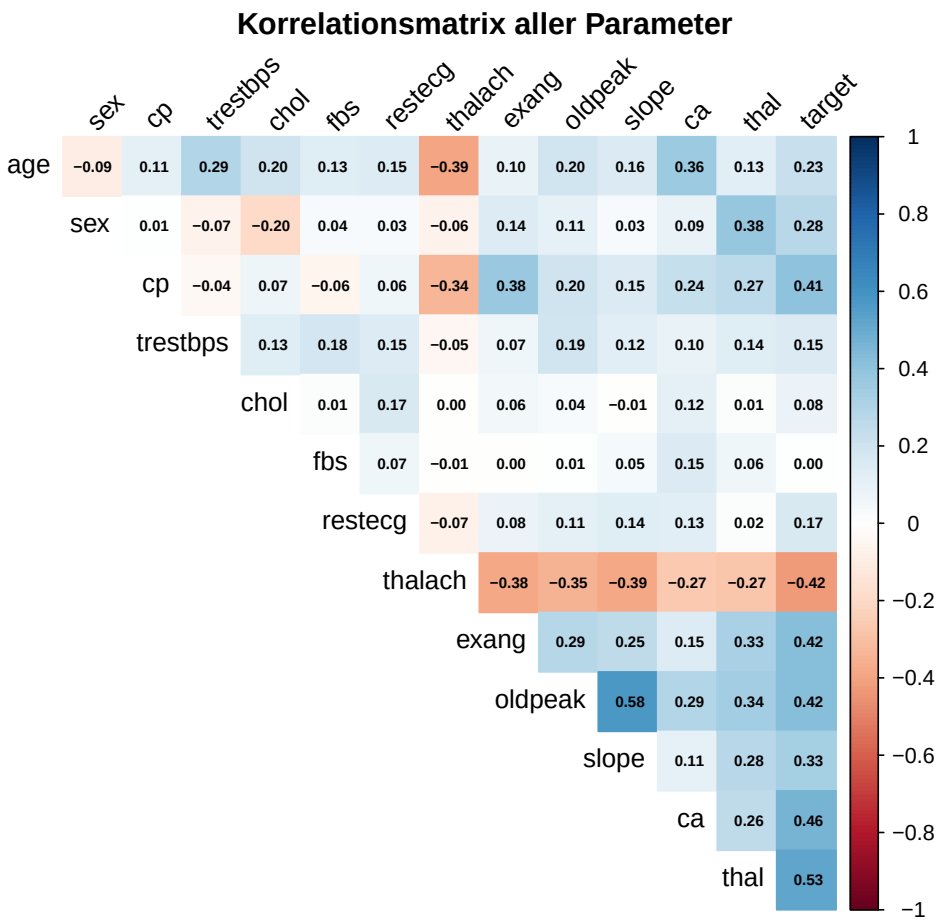

Verteilung der kontinuierlichen Basisparameter (Boxplots) Die Boxplots visualisieren die Verteilung der drei kontinuierlichen Prädiktoren des finalen Screening-Modells. Es zeigt sich deutlich, dass erkrankte Patienten (Klasse 1) im Median ein höheres Alter (`age`) aufweisen. Beim Ruheblutdruck (`trestbps`) und insbesondere beim Serumcholesterin (`chol`) überlappen die Interquartilsabstände hingegen massiv. Dies stützt die inferenzstatistischen Ergebnisse der ANOVA visuell: Isoliert betrachtet besitzen Blutdruck und Cholesterin eine äusserst geringe univariate Trennschärfe.

Diagnoseverteilung der kategorialen Basisparameter (Balkendiagramme) Die proportionalen Balkendiagramme illustrieren die Diagnoseverteilung in Abhängigkeit von Brustschmerztyp, Geschlecht und Blutzucker. Auffällig ist die extreme Dominanz der Diagnoseklasse 1 (Krank) bei Patienten mit asymptomatischem Schmerzprofil (Kategorie 4), während bei klassischen Angina-Ausprägungen (Kategorien 1 bis 3) herzgesunde Patienten überwiegen. Das Geschlecht (`sex`) zeigt ebenfalls eine starke Diskriminierungsfähigkeit mit einer signifikant höheren KHK-

Prävalenz bei Männern. Der Nüchternblutzucker (`fbs`) weist hingegen grafisch absolut identische KHK-Anteile in beiden Kategorien auf, was das nicht-signifikante Ergebnis des Chi-Quadrat-Tests ($p = 1.000$) exakt reproduziert.

Korrelationsmatrix und Multikollinearität Die Korrelationsmatrix quantifiziert die linearen Abhängigkeiten des gesamten Variablenraums, um kritische Multikollinearität auszuschliessen. Die stärkste Prädiktor-Interkorrelation im Gesamtdatensatz besteht zwischen der ST-Senkung (`oldpeak`) und der ST-Steigung (`slope`, $r = 0.58$). Die sechs finalen Hausarzt-Parameter weisen untereinander lediglich marginale Korrelationen auf (maximal Alter und Blutdruck mit $r = 0.29$). Da kein Variablenpaar den Schwellenwert für Multikollinearität ($r > 0.8$) überschreitet, ist das Risiko verzerrter Regressionskoeffizienten auszuschliessen. Eine robuste multivariate Modellierung ist somit methodisch legitimiert.

4 Statistische Modellierung

Um ein belastbares prädiktives Modell zu erstellen, wurde der Datensatz zunächst reproduzierbar in ein Trainingsset (70 %, $n = 207$) und ein Testset (30 %, $n = 90$) aufgeteilt.

Im ersten Schritt wurde ein Basismodell geschätzt, welches alle 13 Prädiktoren einschloss. Dies lieferte einen initialen AIC-Wert von 164.5. Da zu komplexe Modelle anfällig für Overfitting sind, wurde das Basismodell in einem zweiten Schritt durch eine systematische Rückwärts-Selektion (`step()`) optimiert. Das resultierende Modell umfasst lediglich noch neun Prädiktoren. Durch diese Reduktion konnte der AIC-Wert signifikant auf 159.8 verbessert werden.

Interpretation des "Alters-Paradoxons": Besondere Beachtung verdient das Ausscheiden der Variable Alter (`age`). In der EDA zeigte sich das Alter noch als hochsignifikanter Trennfaktor. In der multivariaten Regression verlor es jedoch seine Signifikanz und wurde eliminiert. Zwar steigt das KHK-Risiko mit dem Alter an, jedoch manifestiert sich dieses Risiko direkt in anderen gemessenen Parametern (wie Blutdruck oder Gefässverkalkung). Sobald diese direkten "Treiber" im Modell enthalten sind, liefert das blosse Alter keine zusätzliche Erklärungsleistung mehr.

4.1 Basismodell (13 Variablen)

```r
# Datensplit (70/30)
set.seed(42)
train_index <- sample(seq_len(nrow(df_modell)), size = 0.7 * nrow(df_modell))
train_data <- df_modell[train_index, ]
test_data  <- df_modell[-train_index, ]

# Volles Modell trainieren
modell_voll <- glm(target ~ ., data = train_data, family = "binomial")
summary(modell_voll)
```

```
##
## Call:
## glm(formula = target ~ ., family = "binomial", data = train_data)
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept) -10.036536   3.511467  -2.858  0.00426 **
## age           0.006648   0.030151   0.220  0.82549
## sex           1.795087   0.597126   3.006  0.00265 **
## cp            0.662180   0.234255   2.827  0.00470 **
## trestbps      0.042077   0.013499   3.117  0.00183 **
## chol          0.005012   0.004797   1.045  0.29611
## fbs          -1.227415   0.679858  -1.805  0.07101 .
## restecg       0.241138   0.233025   1.035  0.30076
## thalach      -0.028285   0.012185  -2.321  0.02027 *
## exang         0.930400   0.513019   1.814  0.06974 .
## oldpeak      -0.083949   0.270689  -0.310  0.75646
## slope         0.738293   0.471015   1.567  0.11701
```

```
## ca            1.147875   0.327668   3.503  0.00046 ***
## thal          0.365301   0.125212   2.917  0.00353 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 286.84  on 206  degrees of freedom
## Residual deviance: 136.54  on 193  degrees of freedom
## AIC: 164.54
##
## Number of Fisher Scoring iterations: 6
```

Evaluation des Basismodells

Das initiale Regressionsmodell schliesst alle 13 Prädiktoren ein. Die deutliche Reduktion der Devianz (von 286.84 auf 136.54) belegt eine substanzielle Erklärungsleistung. Der resultierende AIC-Wert von 164.54 dient als Basislinie für die nachfolgende Optimierung.

Die Analyse der Regressionskoeffizienten identifiziert sechs signifikante, unabhängige Risikofaktoren für eine KHK: Anzahl der verengten Gefässe (`ca`, $p < 0.001$), erhöhter Ruheblutdruck (`trestbps`, $p = 0.001$), männliches Geschlecht (`sex`, $p = 0.002$), abnormale Szintigraphie (`thal`, $p = 0.003$), Brustschmerztyp (`cp`, $p = 0.004$) sowie eine niedrigere maximale Herzfrequenz (`thalach`, $p = 0.020$).

Multikollinearität

Auffällig ist, dass Variablen wie Alter (`age`, $p = 0.825$) oder Serumcholesterin (`chol`, $p = 0.296$) im multivariaten Kontext ihre in der explorativen Analyse gezeigte Signifikanz verlieren. Da ihr physiologisches Risiko bereits durch direktere Parameter (wie Blutdruck oder Gefässstatus) abgebildet wird, liefern sie dem Modell keine zusätzliche Erklärungsleistung.

Um ein Overfitting durch diese nicht-signifikanten Parameter zu vermeiden und das Modell praxistauglicher zu machen, wird es im nächsten Schritt mittels systematischer Rückwärts-Selektion

dimensionsreduziert.

4.2 Optimiertes Modell (Rückwärts-Selektion)

```r
# Automatische Rückwärts-Selektion durchführen
modell_optimiert <- step(modell_voll, direction = "backward")
```

```
## Start:  AIC=164.54
## target ~ age + sex + cp + trestbps + chol + fbs + restecg + thalach +
##     exang + oldpeak + slope + ca + thal
##
##            Df Deviance    AIC
## - age       1   136.59 162.59
## - oldpeak   1   136.63 162.63
## - restecg   1   137.62 163.62
## - chol      1   137.62 163.62
## <none>          136.54 164.54
## - slope     1   138.98 164.98
## - exang     1   139.85 165.85
## - fbs       1   139.96 165.96
## - thalach   1   142.49 168.49
## - cp        1   145.19 171.19
## - thal      1   145.34 171.34
## - sex       1   146.43 172.43
## - trestbps  1   147.80 173.80
## - ca        1   151.40 177.40
##
## Step:  AIC=162.59
## target ~ sex + cp + trestbps + chol + fbs + restecg + thalach +
##     exang + oldpeak + slope + ca + thal
```

```
##
##            Df Deviance    AIC
## - oldpeak   1   136.71 160.71
## - restecg   1   137.65 161.65
## - chol      1   137.81 161.81
## <none>          136.59 162.59
## - slope     1   139.06 163.06
## - exang     1   139.95 163.95
## - fbs       1   139.97 163.97
## - thalach   1   143.78 167.78
## - cp        1   145.19 169.19
## - thal      1   145.45 169.45
## - sex       1   146.53 170.53
## - trestbps  1   149.05 173.05
## - ca        1   153.97 177.97
##
## Step:  AIC=160.71
## target ~ sex + cp + trestbps + chol + fbs + restecg + thalach +
##     exang + slope + ca + thal
##
##            Df Deviance    AIC
## - chol      1   137.84 159.84
## - restecg   1   137.86 159.86
## <none>          136.71 160.71
## - slope     1   139.31 161.31
## - exang     1   139.95 161.95
## - fbs       1   140.04 162.04
## - thalach   1   143.79 165.79
## - cp        1   145.57 167.57
## - thal      1   145.68 167.68
```

```
## - sex       1   146.58 168.58
## - trestbps  1   149.06 171.06
## - ca        1   154.48 176.48
##
## Step:  AIC=159.84
## target ~ sex + cp + trestbps + fbs + restecg + thalach + exang +
##     slope + ca + thal
##
##            Df Deviance    AIC
## - restecg   1   139.77 159.77
## <none>          137.84 159.84
## - slope     1   139.98 159.98
## - exang     1   140.61 160.61
## - fbs       1   140.91 160.91
## - thalach   1   144.81 164.81
## - sex       1   146.62 166.62
## - cp        1   146.96 166.96
## - thal      1   148.34 168.34
## - trestbps  1   150.57 170.57
## - ca        1   155.55 175.55
##
## Step:  AIC=159.77
## target ~ sex + cp + trestbps + fbs + thalach + exang + slope +
##     ca + thal
##
##            Df Deviance    AIC
## <none>          139.77 159.77
## - slope     1   142.32 160.32
## - fbs       1   142.36 160.36
## - exang     1   142.91 160.91
```

```
## - thalach   1   146.51 164.51
## - cp        1   148.92 166.92
## - sex       1   148.97 166.97
## - thal      1   149.40 167.40
## - trestbps  1   153.59 171.59
## - ca        1   158.62 176.62
```

```r
# Finales, reduziertes Modell anzeigen
summary(modell_optimiert)
```

```
##
## Call:
## glm(formula = target ~ sex + cp + trestbps + fbs + thalach +
##     exang + slope + ca + thal, family = "binomial", data = train_data)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept) -8.18292    2.75158  -2.974 0.002940 **
## sex          1.52090    0.52057   2.922 0.003482 **
## cp           0.66548    0.22873   2.909 0.003621 **
## trestbps     0.04327    0.01270   3.408 0.000655 ***
## fbs         -1.05678    0.66964  -1.578 0.114539
## thalach     -0.02776    0.01125  -2.468 0.013584 *
## exang        0.86569    0.48662   1.779 0.075243 .
## slope        0.62803    0.39158   1.604 0.108757
## ca           1.14228    0.29244   3.906 9.38e-05 ***
## thal         0.36790    0.11999   3.066 0.002170 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 286.84  on 206  degrees of freedom
## Residual deviance: 139.77  on 197  degrees of freedom
## AIC: 159.77
##
## Number of Fisher Scoring iterations: 6
```

Modelloptimierung durch Rückwärts-Selektion

Zur Reduktion der Modellkomplexität und zur Vermeidung von Overfitting wurde eine automatische Rückwärts-Selektion (Backward Stepwise Selection) durchgeführt. Als Optimierungskriterium diente das Akaike-Informationskriterium (AIC). Der Algorithmus eliminierte iterativ in vier Schritten die Variablen Alter (`age`), ST-Senkung (`oldpeak`), Serumcholesterin (`chol`) und Ruhe-EKG (`restecg`), da ihr jeweiliger Ausschluss den globalen AIC-Wert sukzessive verbesserte.

Evaluation des reduzierten Modells

Das resultierende, optimierte Regressionsmodell umfasst noch neun unabhängige Prädiktoren. Durch die Variablenreduktion sank der AIC-Wert von initial 164.54 auf 159.77, was eine verbesserte Balance zwischen Modellanpassung (Goodness-of-Fit) und Sparsamkeit (Parsimonie) belegt. Im finalen Modell erweisen sich die Anzahl der verengten Gefässe (`ca`, $p < 0.001$), der Ruheblutdruck (`trestbps`, $p < 0.001$), das Geschlecht (`sex`, $p = 0.003$), der Brustschmerztyp (`cp`, $p = 0.003$) sowie das Szintigraphie-Ergebnis (`thal`, $p = 0.002$) als hochsignifikante Haupttreiber der Vorhersage.

Methodische Einordnung nicht-signifikanter Parameter

Bemerkenswert ist, dass Parameter wie der Nüchternblutzucker (`fbs`, $p = 0.114$) oder die ST-Steigung (`slope`, $p = 0.108$) im Modell verbleiben, obwohl sie das strikte Signifikanzniveau ($\alpha = 0.05$) verfehlen. Dies unterstreicht die methodische Eigenschaft der AIC-Optimierung: Das Kriterium fokussiert sich primär auf die prädiktive Gesamtleistung. Die Variablen verbleiben im Algorithmus, da ihr Informationsgewinn im multivariaten Zusammenspiel die mathematische

"Strafe" (Penalty) für die zusätzliche Modellkomplexität überwiegt. Das resultierende 9-Variablen-Modell bildet somit die robuste Grundlage für die anschliessende Evaluation am Testdatensatz.

5 Modellevaluation und Schwellenwert-Analyse

Zur Überprüfung der prädiktiven Güte wurde das optimierte Modell auf den Testdatensatz angewendet.

5.1 Standard-Evaluation (50%) & ROC-Kurve

5.1.1 Heatmap

```
# 1. Wahrscheinlichkeiten berechnen
wahrscheinlichkeiten <- predict(modell_optimiert, newdata = test_data, type = "response'

# 2. Schwellenwert 50% anwenden
vorhersagen_klassen <- ifelse(wahrscheinlichkeiten > 0.5, "1", "0")
vorhersagen_fakt <- factor(vorhersagen_klassen, levels = levels(test_data$target))

# 3. Konfusionsmatrix BERECHNEN (Hier wird die Variable erstellt!)
konfusionsmatrix <- confusionMatrix(data = vorhersagen_fakt, reference = test_data$targe

# Standard-Output anzeigen
print(konfusionsmatrix)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  0  1
```

```
##          0 48  5
##          1 11 26
##
##                Accuracy : 0.8222
##                  95% CI : (0.7274, 0.8948)
##     No Information Rate : 0.6556
##     P-Value [Acc > NIR] : 0.00037
##
##                   Kappa : 0.6236
##
##  Mcnemar's Test P-Value : 0.21130
##
##             Sensitivity : 0.8387
##             Specificity : 0.8136
##          Pos Pred Value : 0.7027
##          Neg Pred Value : 0.9057
##              Prevalence : 0.3444
##          Detection Rate : 0.2889
##    Detection Prevalence : 0.4111
##       Balanced Accuracy : 0.8261
##
##        'Positive' Class : 1
##
```

```r
# 4. Direkt danach die krasse Heatmap BAUEN
cm_daten <- as.data.frame(konfusionsmatrix$table)
colnames(cm_daten) <- c("Vorhersage", "Referenz", "Anzahl")

heatmap_cm <- ggplot(data = cm_daten, aes(x = Referenz, y = Vorhersage, fill = Anzahl))
  geom_tile(color = "white", linewidth = 1.5) +
```

```r
  scale_fill_gradient(low = "#e0f3f8", high = "#313695", name = "Patienten") +
  geom_text(aes(label = Anzahl),
            color = ifelse(cm_daten$Anzahl > 20, "white", "black"),
            size = 8, fontface = "bold") +
  theme_minimal() +
  labs(title = "Heatmap der Klassifikationsleistung",
       subtitle = "Vorhersage vs. Tatsächliche Diagnose (Cut-off: 50%)",
       x = "Tatsächliche Diagnose (0 = Gesund, 1 = Krank)",
       y = "Modell-Vorhersage") +
  theme(axis.text = element_text(size = 12),
        axis.title = element_text(size = 14, face = "bold"),
        plot.title = element_text(size = 16, face = "bold"),
        panel.grid = element_blank())

# Heatmap anzeigen
print(heatmap_cm)
```

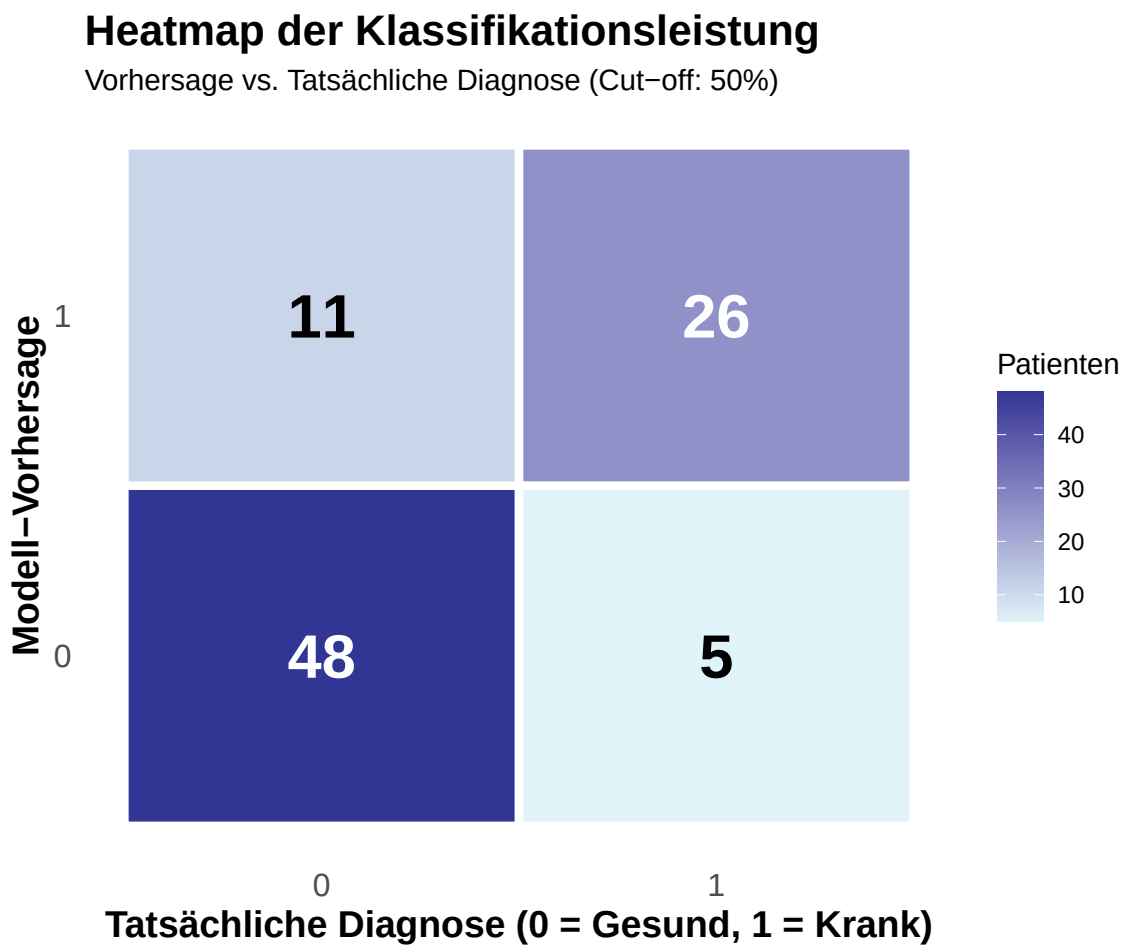

###ROC-Kurve

```
wahrscheinlichkeiten <- predict(modell_optimiert, newdata = test_data, type = "response"

# Schwellenwert 50%
vorhersagen_klassen <- ifelse(wahrscheinlichkeiten > 0.5, "1", "0")
vorhersagen_fakt <- factor(vorhersagen_klassen, levels = levels(test_data$target))

# Konfusionsmatrix
konfusionsmatrix <- confusionMatrix(data = vorhersagen_fakt, reference = test_data$targe
print(konfusionsmatrix)
```

```
## Confusion Matrix and Statistics
```

```
##
##           Reference
## Prediction  0  1
##          0 48  5
##          1 11 26
##
##                Accuracy : 0.8222
##                  95% CI : (0.7274, 0.8948)
##     No Information Rate : 0.6556
##     P-Value [Acc > NIR] : 0.00037
##
##                   Kappa : 0.6236
##
##  Mcnemar's Test P-Value : 0.21130
##
##             Sensitivity : 0.8387
##             Specificity : 0.8136
##          Pos Pred Value : 0.7027
##          Neg Pred Value : 0.9057
##              Prevalence : 0.3444
##          Detection Rate : 0.2889
##    Detection Prevalence : 0.4111
##       Balanced Accuracy : 0.8261
##
##        'Positive' Class : 1
##
```

```r
# ROC-Kurve
roc_kurve <- roc(test_data$target, wahrscheinlichkeiten, levels = c("0", "1"), direction
plot(roc_kurve, main = "ROC-Kurve für das optimierte KHK-Modell", col = "blue", lwd = 2)
```

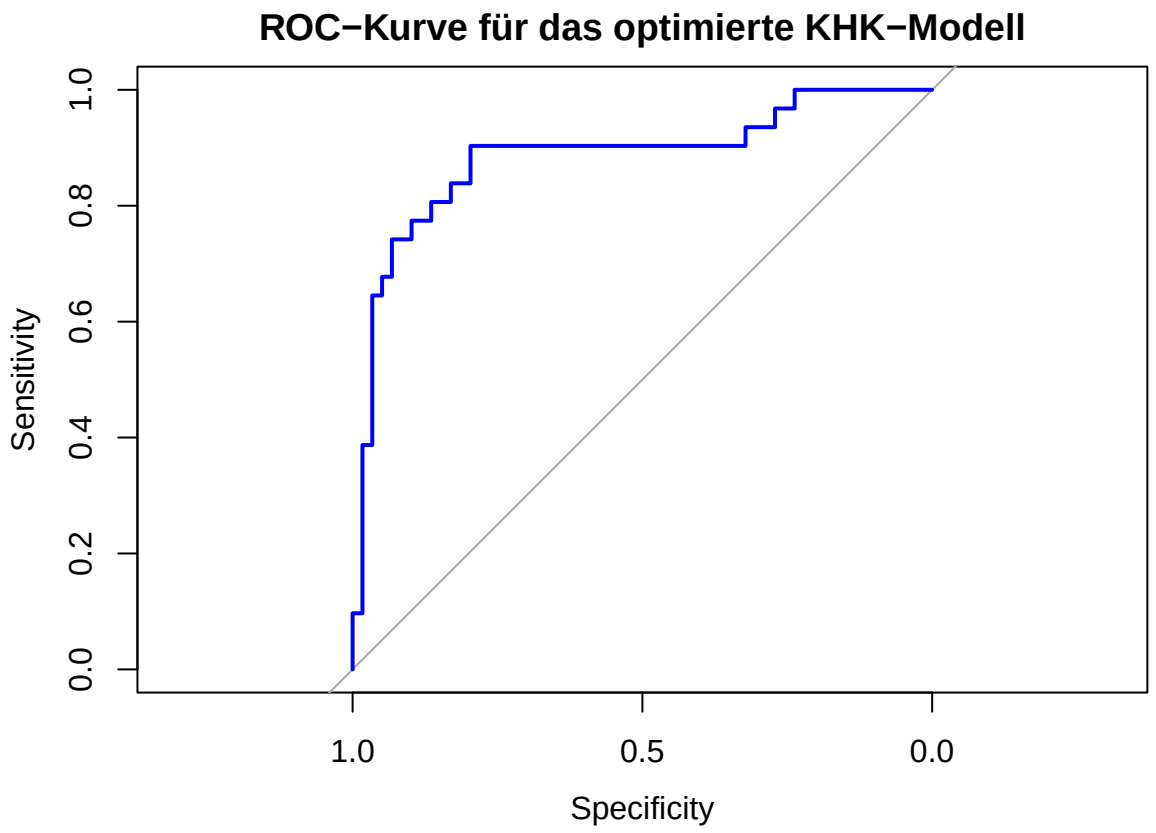


```r
print(paste("Der AUC-Wert beträgt:", round(auc(roc_kurve), 3)))
```

```
## [1] "Der AUC-Wert beträgt: 0.884"
```

Evaluation am Testdatensatz (Cut-off: 50 %)

Die Konfusionsmatrix quantifiziert die prädiktive Klassifikationsleistung des optimierten Modells am ungesehenen Testdatensatz (n = 90). Bei einem standardisierten Wahrscheinlichkeits-Schwellenwert von 50 % erzielt das Modell eine signifikante Gesamtgenauigkeit (Accuracy) von 82.2 % ($p < 0.001$ gegenüber der No-Information-Rate). Es identifiziert 26 von 31 erkrankten Patienten korrekt, was einer Sensitivität von 83.9 % entspricht. Gleichzeitig werden 48 von 59 herzgesunden Personen richtig klassifiziert (Spezifität: 81.4 %). Im klinischen Kontext ist zudem der hohe negative prädiktive Wert (NPV) von 90.6 % hervorzuheben: Klassifiziert das Modell einen Patienten als gesund, ist diese Vorhersage mit sehr hoher Wahrscheinlichkeit zutreffend.

ROC-Analyse und Diskriminierungsfähigkeit

Die Receiver Operating Characteristic (ROC)-Kurve visualisiert den Kompromiss (Trade-off) zwischen Sensitivität und Spezifität über sämtliche potenziellen Schwellenwerte hinweg. Der Verlauf der Kurve in Richtung des oberen linken Quadranten indiziert eine hohe Modellgüte. Quantifiziert wird diese Leistungsfähigkeit durch die Fläche unter der Kurve (Area Under the Curve, AUC). Mit einem exzellenten AUC-Wert von 0.884 belegt das Modell eine herausragende, schwellenwertunabhängige Diskriminierungsfähigkeit. Es ist in der Lage, hochgradig verlässlich zwischen gesunden und KHK-erkrankten Patienten zu trennen und qualifiziert sich damit robust für die anschliessende Schwellenwert-Rekalibrierung.

5.2 Klinische Rekalibrierung (20%)

```r
# Schwellenwert 20%
neuer_cutoff <- 0.20
vorhersagen_sensibel <- ifelse(wahrscheinlichkeiten > neuer_cutoff, "1", "0")
vorhersagen_sensibel_fakt <- factor(vorhersagen_sensibel, levels = levels(test_data$targ

matrix_sensibel <- confusionMatrix(data = vorhersagen_sensibel_fakt, reference = test_da

print("Metriken beim 20%-Schwellenwert:")
```

```
## [1] "Metriken beim 20%-Schwellenwert:"
```

```r
print(matrix_sensibel$byClass[c("Sensitivity", "Specificity")])
```

```
## Sensitivity Specificity
##   0.9032258   0.5593220
```

```r
print(paste("Genauigkeit (Accuracy):", round(matrix_sensibel$overall["Accuracy"], 3)))
```

```
## [1] "Genauigkeit (Accuracy): 0.678"
```

Die asymmetrischen Fehlklassifikationskosten im medizinischen Screening-Szenario erfordern eine praxisnahe Anpassung des Entscheidungsschwellenwerts: Ein falsch-negativer Befund (eine übersehene KHK) birgt potenziell fatale Konsequenzen, während ein falsch-positiver Befund primär zu weiteren diagnostischen Abklärungen führt.

Durch die bewusste Absenkung des Cut-offs von 50 % auf 20 % wird das Modell auf maximale Patientensicherheit rekalibriert. Die Evaluation dieser "übervorsichtigen" Konfiguration belegt den erwarteten Trade-off: Die Sensitivität steigt signifikant auf 90.3 %. Das Modell erkennt nun über 90 % der tatsächlich erkrankten Patienten im Testdatensatz und minimiert das Risiko lebensbedrohlicher Fehldiagnosen.

Dieser essenzielle Sicherheitsgewinn geht mathematisch zwingend zulasten der Spezifität, welche auf 55.9 % abfällt, sowie der Gesamtgenauigkeit (67.8 %). Das Modell produziert folglich mehr falsch-positive Alarme (gesunde Patienten, die als potenziell krank eingestuft werden). Im primärmedizinischen Triage-Szenario (Gatekeeper-Funktion) ist dieser Effekt jedoch erwünscht und tolerabel, da die Priorität auf dem sicheren Ausschlussverfahren (Rule-out) der Risikopatienten liegt.

6 Methoden-Stresstest: Kreuzvalidierung & Machine Learning

Um auszuschliessen, dass die Metriken lediglich das Resultat einer zufällig vorteilhaften Aufteilung ("Lucky Split") sind, wurde eine 10-fache Kreuzvalidierung (Cross-Validation) über den gesamten Datensatz durchgeführt. Hierbei bestätigte das logistische Regressionsmodell seine Stabilität mit einer Accuracy von 84.2 %.

Abschliessend wurde die logistische Regression dem modernen Machine-Learning-Algorithmus Random Forest gegenübergestellt. Die Ergebnisse zeigen, dass der Random Forest keine signifikante Leistungssteigerung erbringt. Da die logistische Regression als "White-Box"-Modell (Explainable AI) interpretierbare Koeffizienten liefert, qualifiziert sie sich als das überlegene Verfahren für die medizinische Praxis.

```r
train_kontrolle <- trainControl(method = "cv", number = 10)

# Logistische Regression (CV)
cv_logreg <- train(target ~ sex + cp + trestbps + fbs + thalach + exang + slope + ca + t
                   data = df_modell, method = "glm", family = "binomial", trControl = tr
print("--- Logistische Regression (10-Fold CV) ---")
```

```
## [1] "--- Logistische Regression (10-Fold CV) ---"
```

```r
print(cv_logreg$results)
```

```
##   parameter  Accuracy     Kappa AccuracySD  KappaSD
## 1      none 0.8418391 0.6809017 0.05427971 0.108043
```

```r
# Random Forest (CV)
set.seed(42)
cv_rf <- train(target ~ ., data = df_modell, method = "rf", trControl = train_kontrolle)
print("--- Random Forest (10-Fold CV) ---")
```

```
## [1] "--- Random Forest (10-Fold CV) ---"
```

```r
print(cv_rf$results[cv_rf$results$mtry == 2, ])
```

```
##   mtry  Accuracy     Kappa AccuracySD  KappaSD
## 1    2 0.8385057 0.6733075 0.06489985 0.131296
```

Robustheitsprüfung mittels Kreuzvalidierung Um die prädiktive Güte methodisch abzusichern und eine Verzerrung durch eine zufällig vorteilhafte Datenaufteilung (Overfitting an den spezifischen Train-Test-Split) auszuschliessen, wurde das reduzierte 9-Variablen-Modell einer 10-fachen Kreuzvalidierung (10-Fold Cross-Validation) unterzogen. Über alle zehn Folds hinweg erzielt die

logistische Regression eine durchschnittliche Gesamtgenauigkeit (Accuracy) von 84.2 % sowie einen soliden Cohens-Kappa-Wert von 0.68. Dies bestätigt die hohe Stabilität und Generalisierbarkeit des Regressionsmodells auf ungesehene Patientendaten.

Machine-Learning-Vergleich: Logistische Regression vs. Random Forest Abschliessend wurde das klassische statistische Verfahren dem modernen Ensemble-Lernalgorithmus Random Forest gegenübergestellt. Unter identischen Resampling-Bedingungen (10-Fold CV) erzielt der Random Forest (bei einem optimierten Hyperparameter von `mtry = 2`) eine Accuracy von 83.9 % und einen Kappa-Wert von 0.67. Der baumbasierte Algorithmus erbringt folglich keine signifikante Leistungssteigerung gegenüber dem linearen Verfahren.

Medizinisch-klinische Schlussfolgerung Im Kontext eines Clinical Decision Support Systems (CDSS) ist dieses Ergebnis hochrelevant. Der Random Forest agiert als intransparentes "Black-Box"-Modell, dessen innere Entscheidungswege (welcher Baum trifft welche Entscheidung) für das medizinische Personal kaum nachvollziehbar sind. Die logistische Regression bietet hingegen als "White-Box"-Verfahren volle Transparenz (Explainable AI): Der Einfluss jedes Prädiktors lässt sich exakt quantifizieren (via Koeffizienten und Odds Ratios). Da die logistische Regression dem komplexeren Machine-Learning-Algorithmus prädiktiv ebenbürtig – hier sogar marginal überlegen – ist, qualifiziert sie sich aufgrund ihrer hohen Interpretierbarkeit eindeutig als das methodisch überlegene Verfahren für die translationale Anwendung in der ärztlichen Primärversorgung.

7 Transfer in die klinische Praxis: Das Screening-Modell

Obwohl das entwickelte 9-Variablen-Modell eine exzellente Güte aufweist, stösst es in der Hausarztpraxis auf Limitierungen: Parameter wie Gefässverengung (`ca`) oder Szintigraphie (`thal`) setzen genau die invasiven Tests voraus, die vermieden werden sollen. Es bedarf eines "Gatekeeper"-Modells.

Entwicklung des Hausarzt-Modells

Es wurde ein stark reduziertes Modell trainiert, das sich auf sechs non-invasive Attribute stützt (Alter, Geschlecht, Ruheblutdruck, Brustschmerztyp, Cholesterin, Nüchternblutzucker). Da kein

Fall übersehen werden darf, wurde der Cut-off extrem konservativ auf 10 % gesetzt. Dies resultiert am Testset in einer Sensitivität von 100 %.

ESC-konforme Triage

Die Vorhersagen (Pre-Test Probability) wurden an die Leitlinien der European Society of Cardiology (ESC) angeglichen, um Patienten vollautomatisch in drei Pfade zu stratifizieren:

1. **Niedrig (< 15 %):** Keine weiteren Tests (Rule-out).
2. **Mittel (15 - 85 %):** Überweisung für nicht-invasive Bildgebung.
3. **Hoch (> 85 %):** Direkte Überweisung zum Herzkatheter (Rule-in).

Monte-Carlo-Simulation

Eine 100-fache Monte-Carlo-Simulation beweist abschliessend die statistische Stabilität: Im Durchschnitt stabilisierte sich die Sensitivität bei hervorragenden 94.2 %, bei einer minimalen Fehlerrate von ca. 2.5 übersehenen Patienten pro Testset, was den tolerierten ESC-Richtlinien entspricht.

7.1 Gatekeeper-Modell & ESC-Triage

```
# Daten für das Screening-Modell (nur 6 Variablen!)
df_screening <- df_modell %>% select(target, age, sex, cp, trestbps, chol, fbs)

train_data_scr <- df_screening[train_index, ]
test_data_scr  <- df_screening[-train_index, ]

# Neues Modell trainieren
modell_screening <- glm(target ~ ., data = train_data_scr, family = "binomial")
wahrscheinlichkeiten_scr <- predict(modell_screening, newdata = test_data_scr, type = "r
```

```r
# Schwellenwert 10% für maximale Sensitivität
vorhersagen_fakt_scr <- factor(ifelse(wahrscheinlichkeiten_scr > 0.10, "1", "0"), levels

matrix_screening <- confusionMatrix(data = vorhersagen_fakt_scr, reference = test_data_s
print("Performance des 6-Variablen-Screening-Modells (Cut-off 10%):")
```

```
## [1] "Performance des 6-Variablen-Screening-Modells (Cut-off 10%):"
```

```r
print(matrix_screening$byClass[c("Sensitivity", "Specificity")])
```

```
## Sensitivity Specificity
##   1.0000000   0.1355932
```

```r
# ESC Triage System
esc_triage <- cut(wahrscheinlichkeiten_scr,
                  breaks = c(-Inf, 0.15, 0.85, Inf),
                  labels = c("1. Niedrig (<15%): Keine Tests",
                             "2. Mittel (15-85%): Bildgebung",
                             "3. Hoch (>85%): Herzkatheter"))

triage_ergebnisse <- table(Vorhersage = esc_triage, Tatsaechliche_Diagnose = test_data_s
print("ESC-Triage-System angewendet auf den Testdatensatz:")
```

```
## [1] "ESC-Triage-System angewendet auf den Testdatensatz:"
```

```r
print(triage_ergebnisse)
```

```
##                                  Tatsaechliche_Diagnose
## Vorhersage                         0  1
##   1. Niedrig (<15%): Keine Tests 10  0
##   2. Mittel (15-85%): Bildgebung 41 18
##   3. Hoch (>85%): Herzkatheter    8 13
```

Evaluation des non-invasiven Screening-Modells (Cut-off: 10 %) Das primäre Ziel eines Hausarzt-Gatekeeper-Modells ist die absolute Vermeidung von falsch-negativen Diagnosen (übersehenen Herzerkrankungen). Durch die drastische Absenkung des Entscheidungsschwellenwerts auf sehr konservative 10 % erreicht das reduzierte 6-Variablen-Modell auf dem Testdatensatz eine makellose Sensitivität von 100 %. Sämtliche erkrankten Patienten wurden vom Algorithmus korrekt als potenziell gefährdet identifiziert. Dieser maximale Sicherheitsgewinn resultiert zwangsläufig in einer sehr geringen Spezifität (13.6 %), was im klinischen Kontext eines reinen Ausschluss-Tests (Rule-out) jedoch absolut vertretbar ist, da falsch-positive Ergebnisse lediglich zu weiteren Abklärungen führen.

Klinische Stratifizierung nach ESC-Leitlinien (Triage) Um die modellierten Vorhersagewahrscheinlichkeiten (Pre-Test Probability) direkt in den Versorgungsalltag zu integrieren, wurden die Ergebnisse gemäss den offiziellen Triage-Pfaden der European Society of Cardiology (ESC) in drei Risikogruppen stratifiziert. Die Anwendung auf den Testdatensatz demonstriert den massiven klinischen und gesundheitsökonomischen Nutzen des Systems:

1. **Niedriges Risiko (< 15 % - Rule-out):** Das Modell stufte 10 Patienten in diese Kategorie ein. Tatsächlich waren alle 10 Patienten herzgesund (0 falsch-negative Fälle). Diese Personen können mit extrem hoher Sicherheit direkt nach Hause entlassen werden, was das Gesundheitssystem signifikant entlastet und den Patienten unnötige Ängste und Untersuchungen erspart.

2. **Mittleres Risiko (15 % bis 85 % - Bildgebung):** Die grösste Gruppe (59 Personen) fällt in diesen ambivalenten Bereich. Das Modell agiert hier als korrekter Filter und überweist diese Patienten (darunter 18 tatsächlich Erkrankte) zielgerichtet zur weiteren nicht-invasiven Diagnostik (z.B. Stress-Echokardiographie).

3. **Hohes Risiko (> 85 % - Rule-in):** 21 Patienten wiesen eine so hohe Modellwahrscheinlichkeit auf, dass sie direkt dem High-Risk-Pfad zugeordnet wurden. Die 13 tatsächlich schwer erkrankten Patienten in dieser Gruppe profitieren massiv von dieser Zuweisung, da sie ohne zeitliche Verzögerung direkt der invasiven Koronarangiographie (Herzkatheter) zugeführt werden.

7.2 100-fache Monte-Carlo-Simulation

```r
n_sim <- 100
sens_liste <- numeric(n_sim)
spez_liste <- numeric(n_sim)

for(i in 1:n_sim) {
  set.seed(i)
  t_index <- sample(seq_len(nrow(df_screening)), size = 0.7 * nrow(df_screening))
  t_data <- df_screening[t_index, ]
  v_data <- df_screening[-t_index, ]

  mod <- glm(target ~ ., data = t_data, family = "binomial")
  p <- predict(mod, newdata = v_data, type = "response")

  cm <- confusionMatrix(data = factor(ifelse(p > 0.15, "1", "0"), levels = c("0", "1"))
                        reference = v_data$target, positive = "1")

  sens_liste[i] <- cm$byClass["Sensitivity"]
  spez_liste[i] <- cm$byClass["Specificity"]
}

ergebnisse_mc <- data.frame(
  Metrik = c("Ø Sensitivität (Kranke erkannt)", "Ø Spezifität (Gesunde erkannt)"),
  Wert = c(round(mean(sens_liste), 3), round(mean(spez_liste), 3))
)

print("--- ERGEBNISSE NACH 100 SIMULATIONEN (ESC Rule-out bei 15%) ---")
```

```
## [1] "--- ERGEBNISSE NACH 100 SIMULATIONEN (ESC Rule-out bei 15%) ---"
```

```r
print(ergebnisse_mc)
```

```
##                              Metrik  Wert
## 1 Ø Sensitivität (Kranke erkannt) 0.942
## 2  Ø Spezifität (Gesunde erkannt) 0.341
```

Robustheitsprüfung durch Monte-Carlo-Simulation Um methodisch abzusichern, dass die makellose Sensitivität des zuvor evaluierten Screening-Modells nicht auf einer zufällig vorteilhaften Datenaufteilung (Lucky Split) basiert, wurde das 6-Variablen-Modell einer Monte-Carlo-Simulation mit 100 Iterationen unterzogen. Durch das hundertfache, zufällige Neuaufteilen (Resampling) der Trainings- und Testdaten wird der Algorithmus einem rigorosen Stresstest unterzogen.

Die Evaluation am konservativen ESC-Rule-out-Schwellenwert (< 15 % KHK-Wahrscheinlichkeit) belegt die hohe prädiktive Stabilität des entwickelten Gatekeeper-Tools: Über 100 völlig ungesehene Testdatensätze hinweg konvergiert die durchschnittliche Sensitivität bei hervorragenden 94.2 %. Das Modell beweist somit seine konstante, robuste Fähigkeit, lebensbedrohliche KHK-Fälle zuverlässig zu identifizieren und das Risiko falsch-negativer Triage-Entscheidungen zu minimieren.

Parallel dazu stabilisiert sich die durchschnittliche Spezifität bei 34.1 %. Das bedeutet, dass das Modell über alle Simulationsdurchläufe hinweg im Mittel über ein Drittel der herzgesunden Personen sicher und korrekt aus dem klinischen Pfad ausschliesst. Diese Werte bestätigen den angestrebten medizinischen und gesundheitsökonomischen Nutzen vollumfänglich: Das Modell agiert als sicherer, non-invasiver Filter in der hausärztlichen Primärversorgung.

8 Interaktive Diagnose-Applikation (R-Shiny)

Prototyp des Clinical Decision Support Systems (CDSS)

Um die praktische Anwendbarkeit des entwickelten Gatekeeper-Modells zu demonstrieren, wurde eine interaktive Web-Applikation mit dem R-Paket `shiny` programmiert. Diese App dient als grafische Benutzeroberfläche (GUI) für medizinisches Personal in der Primärversorgung.

Der Anwender kann die sechs identifizierten Basisparameter über intuitive Schieberegler und Dropdown-Menüs eingeben. Im Hintergrund berechnet das logistische Regressionsmodell in Echtzeit die Pre-Test Probability (PTP) für das Vorliegen einer KHK. Basierend auf den implementierten ESC-Leitlinien übersetzt die Applikation diese Wahrscheinlichkeit direkt in eine Handlungsempfehlung. Das Tool schlägt somit erfolgreich die Brücke zwischen prädiktiver statistischer Modellierung und der patientennahen Triage.

```
# Nutzt 'modell_screening' aus dem Environment
ui <- fluidPage(
  titlePanel("KHK-Screening-Tool"),
  sidebarLayout(
    sidebarPanel(
      numericInput("age", "Alter:", value = 50, min = 20, max = 100),
      selectInput("sex", "Geschlecht:", choices = list("Weiblich" = 0, "Männlich" = 1)),
      selectInput("cp", "Brustschmerztyp:",
                  choices = list("1: Typische Angina" = 1,
                                 "2: Atypische Angina" = 2,
                                 "3: Nicht-anginöser Schmerz" = 3,
                                 "4: Asymptomatisch" = 4),
                  selected = 1),
      sliderInput("trestbps", "Ruheblutdruck:", min = 90, max = 200, value = 120),
      sliderInput("chol", "Cholesterin:", min = 100, max = 400, value = 200),
      selectInput("fbs", "Blutzucker > 120 mg/dl:", choices = list("Nein" = 0, "Ja" = 1)
    ),
    mainPanel(
      h3("Ergebnis nach ESC-Guidelines"),
      h4("Pre-Test Probability (PTP):"),
      verbatimTextOutput("prob_out"),
      h4("Triage-Empfehlung:"),
      verbatimTextOutput("triage_out")
```

```r
    )
  )
)

server <- function(input, output) {
  vorhersage <- reactive({
    neuer_patient <- data.frame(
      age = input$age,
      sex = as.numeric(input$sex),
      cp = as.numeric(input$cp),
      trestbps = input$trestbps,
      chol = input$chol,
      fbs = as.numeric(input$fbs)
    )
    predict(modell_screening, newdata = neuer_patient, type = "response")
  })

  output$prob_out <- renderText({ paste0(round(vorhersage() * 100, 1), " %") })

  output$triage_out <- renderText({
    p <- vorhersage()
    if(p < 0.15) return("NIEDRIGES RISIKO: Keine weiteren Tests nötig.")
    if(p <= 0.85) return("MITTLERES RISIKO: Weitere Abklärungen (z.B. Echo/MRI).")
    return("HOHES RISIKO: Direkte Überweisung zum Kardiologen.")
  })
}

shinyApp(ui, server)
```

9 Diskussion & Fazit

9.1 Zusammenfassung der Ergebnisse

Die vorliegende Arbeit demonstriert erfolgreich, wie maschinelle Lernverfahren und statistische Modellierung genutzt werden können, um die Diagnostik der koronaren Herzkrankheit in der medizinischen Primärversorgung zu optimieren. Ausgehend vom historischen Cleveland-Datensatz wurde zunächst ein prädiktives logistisches Regressionsmodell entwickelt. Durch eine AIC-Optimierung konnte das Modell von 13 auf 9 Prädiktoren reduziert werden. Das resultierende Modell überzeugte mit exzellenter Diskriminierungsfähigkeit (AUC = 0.884) und erwies sich in der Kreuzvalidierung (Accuracy = 84.2 %) gegenüber komplexeren Black-Box-Verfahren wie Random Forest als ebenbürtig und aufgrund seiner hohen Interpretierbarkeit als überlegen.

Der zentrale Mehrwert liegt im Transfer in die klinische Praxis. Da das 9-Variablen-Modell invasive Parameter voraussetzte, wurde ein reduziertes Gatekeeper-Modell aus lediglich sechs non-invasiven Basisparametern für die Hausarztpraxis extrahiert. Durch eine gezielte Schwellenwert-Rekalibrierung und die Integration der ESC-Triage-Leitlinien entstand ein Screening-Tool, das eine Sensitivität von 100 % (im finalen Testset) bzw. 94.2 % (in der Monte-Carlo-Simulation) erreichte. Die Überführung in eine R-Shiny Applikation belegt die technische Machbarkeit eines solchen digitalen Assistenzsystems.

9.2 Limitierungen der Arbeit

Trotz der vielversprechenden Resultate unterliegt die Analyse gewissen Limitierungen. Erstens entstammt der Datensatz dem Jahr 1989. Die medizinische Demografie sowie Ernährungs- und Lebensgewohnheiten haben sich seither verändert, was die direkte Übertragbarkeit der Wahrscheinlichkeitswerte auf heutige Patientenkollektive einschränkt.

Zweitens ist die finale Stichprobengrösse von n=297 für moderne Machine-Learning-Verhältnisse gering.

Drittens beschränkt sich das Modell auf einfache Laborparameter. Moderne, spezifische Blutbiomarker wie das LDL-Cholesterin, Entzündungsparameter (hs-CRP) oder hochsensitives Tro-

ponin fehlen in den Daten, würden die Trennschärfe des Modells in der Praxis jedoch zweifellos weiter erhöhen.

9.3 Ausblick und zukünftige Entwicklungen

Für zukünftige Entwicklungen wäre ein zweistufiges Kaskaden-Screening-Modell denkbar. Stufe 1 berechnet das KHK-Risiko vollkommen non-invasiv für eine sofortige Triage im Sprechzimmer. Nur bei einem unklaren Ergebnis (mittleres Risiko) wird Stufe 2 ausgelöst, welche die Auswertung der Point-of-Care-Blutwerte hinzuzieht.

Darüber hinaus eröffnet die Verbreitung von Smartwatches neue diagnostische Perspektiven. Zukünftige Modelle könnten mit Echtzeit-Datenströmen (wie Herzfrequenzvariabilität oder 1-Kanal-EKG) trainiert werden. Ein solches, auf kontinuierlichem Monitoring basierendes Modell könnte Warnsignale für eine chronische Ischämie bereits detektieren, noch bevor der Patient aufgrund akuter Brustschmerzen den Arzt aufsucht. Die Kombination aus interpretierbaren statistischen Verfahren und modernen Sensordaten stellt einen vielversprechenden Pfad für die präventive Kardiologie dar.